



UNIVERSIDADE SÃO JUDAS TADEU

ENGENHARIA DE SOFTWARE

CAETANO AVILA CABRERA 825131333

DANIEL ARAÚJO SANTOS 825130157

GABRIEL SOUSA SILVA 825143903

GUSTAVO ANTUNES TRESSENO DOS SANTOS 825155450

MARCELO VITA MARCOMINI 82516000

ROBERTO LUIS BOTELHO CUNHA 825153396

WILLIAM LEITE BATISTA 8261108642

PROJETO A3 INTELIGÊNCIA ARTIFICIAL

ANÁLISE PREDITIVA DE DOENÇAS CARDÍACAS

SÃO PAULO

2026

Caetano Avila Cabrera 825131333
Daniel Araújo Santos 825130157
Gabriel Sousa Silva 825143903
Gustavo Antunes Tresseno dos Santos 825155450
Marcelo Vita Marcomini 82516000
Roberto Luis Botelho Cunha 825153396
William Leite Batista 8261108642

PROJETO A3 INTELIGÊNCIA ARTIFICIAL
ANÁLISE PREDITIVA DE DOENÇAS CARDÍACAS

Projeto A3 apresentado ao curso de
Engenharia de Software da
Universidade São Judas Tadeu.

SUMÁRIO

1 INTRODUÇÃO	4
2 DESCRIÇÃO DA BASE DE DADOS	5
3 DEFINIÇÃO DO PROBLEMA (TARGET).....	6
3.1 Variável Target.....	6
3.2 Target	6
3.3 Variáveis Independentes	6
4 PRÉ-PROCESSAMENTO.....	7
4.1 Verificação de Valores Ausentes	7
4.2 Separação entre Features e Target.....	7
4.3 Tratamento das Variáveis Numéricas.....	7
4.4 Tratamento das Variáveis Categóricas.....	7
4.5 Divisão dos Dados	7
5 MODELAGEM.....	8
5.1 K-Nearest Neighbors (KNN).....	8
5.2 Naive Bayes	8
6 SUPPORT VECTOR MACHINE (SVM)	9
6.1 Árvore de Decisão	9
7 CONSTRUÇÃO DO COMITÊ	10
7.1 Votação Majoritária (Hard Voting).....	10
8 RESULTADOS E MÉTRICAS.....	11
8.1 Tabela de Resultados.....	11
8.2 Matriz de Confusão do Comitê.....	11
9 DISCUSSÃO	12
10 CONCLUSÃO	13
REFERÊNCIAS.....	14

1 INTRODUÇÃO

A Inteligência Artificial tem se destacado como uma importante ferramenta para apoio à tomada de decisões em diversas áreas, especialmente na saúde. Por meio de técnicas de Aprendizado de Máquina (Machine Learning), é possível identificar padrões em grandes volumes de dados e realizar previsões com elevado grau de precisão.

As doenças cardiovasculares estão entre as principais causas de mortalidade no mundo, tornando essencial o desenvolvimento de sistemas capazes de auxiliar na detecção precoce dessas condições. Nesse contexto, algoritmos de classificação podem ser utilizados para prever a presença de doenças cardíacas com base em informações clínicas dos pacientes.

O presente trabalho tem como objetivo desenvolver e avaliar diferentes modelos de classificação supervisionada para a predição de doenças cardíacas, além de construir um Comitê de Classificadores (Ensemble Learning) para comparar seu desempenho com os modelos individuais.

2 DESCRIÇÃO DA BASE DE DADOS

Foi utilizada uma base de dados pública obtida na plataforma Kaggle, denominada Heart Disease Dataset. A base contém informações clínicas de pacientes utilizadas para identificar a presença ou ausência de doença cardíaca.

Características da base:

- Total de registros: 1.025 pacientes;
- Total de atributos: 14 colunas;
- Variável alvo (target): 1 coluna;
- Variáveis preditoras (features): 13 atributos.

Entre os principais atributos presentes na base, destacam-se:

- Idade;
- Sexo;
- Tipo de dor no peito;
- Pressão arterial;
- Colesterol;
- Glicemia em jejum;
- Resultados de eletrocardiograma;
- Frequência cardíaca máxima;
- Angina induzida por exercício;
- Outros indicadores clínicos relacionados à saúde cardiovascular.

A distribuição da variável alvo apresentou:

- 526 pacientes com doença cardíaca;
- 499 pacientes sem doença cardíaca.

A escolha dessa base foi motivada pela relevância do problema para a área médica e pela adequação ao desenvolvimento de modelos de classificação supervisionada.

3 DEFINIÇÃO DO PROBLEMA (TARGET)

O objetivo do projeto é prever se um paciente possui ou não doença cardíaca com base em suas características clínicas.

3.1 Variável Target

A variável target utilizada foi a coluna "target", responsável por indicar a presença ou ausência de doença cardíaca nos pacientes.

3.2 Target

Representação:

- 0 = Ausência de doença cardíaca;
- 1 = Presença de doença cardíaca.

3.3 Variáveis Independentes

As variáveis independentes correspondem aos demais atributos da base, utilizados para realizar as previsões do modelo.

O problema pode ser caracterizado como um problema de classificação binária, uma vez que existem apenas duas possíveis classes de saída.

4 PRÉ-PROCESSAMENTO

Antes do treinamento dos modelos, foi realizada uma etapa de preparação dos dados para garantir melhor desempenho dos algoritmos.

As etapas executadas foram:

4.1 Verificação de Valores Ausentes

Inicialmente, foi realizada uma análise para identificar a existência de valores nulos na base de dados.

4.2 Separação entre Features e Target

Os dados foram divididos em:

- X: variáveis independentes;
- y: variável alvo (target).

4.3 Tratamento das Variáveis Numéricas

Foi aplicada:

- Imputação pela mediana para valores ausentes;
- Padronização utilizando StandardScaler.

4.4 Tratamento das Variáveis Categóricas

Foi aplicada:

- Imputação pela moda;
- Codificação One-Hot Encoding.

4.5 Divisão dos Dados

A base foi dividida em:

- 80% para treinamento (820 registros);
- 20% para teste (205 registros).

Também foi utilizada estratificação para manter a proporção das classes nos conjuntos de treino e teste.

5 MODELAGEM

Foram treinados quatro classificadores supervisionados.

5.1 K-Nearest Neighbors (KNN)

O algoritmo KNN classifica novos exemplos com base nos vizinhos mais próximos.

Parâmetro utilizado:

- `n_neighbors = 5`.

5.2 Naive Bayes

Foi utilizado o modelo Gaussian Naive Bayes, baseado em probabilidades condicionais.

6 SUPPORT VECTOR MACHINE (SVM)

O algoritmo SVM foi configurado com:

- Kernel RBF;
- Probability = True;
- Random State = 42.

6.1 Árvore de Decisão

O modelo foi configurado com:

- Max Depth = 5;
- Random State = 42.

Todos os modelos foram treinados e avaliados individualmente.

7 CONSTRUÇÃO DO COMITÊ

Após o treinamento dos classificadores individuais, foi construído um Comitê de Classificadores utilizando a técnica Ensemble Learning.

A estratégia adotada foi:

7.1 Votação Majoritária (Hard Voting)

Participaram do comitê:

- KNN;
- Naive Bayes;
- SVM;
- Árvore de Decisão.

Nesse método, cada classificador realiza sua previsão individualmente e a classe mais votada é considerada como resultado final. A escolha dessa abordagem ocorreu devido à sua simplicidade e capacidade de combinar diferentes perspectivas de classificação, reduzindo erros individuais dos modelos.

8 RESULTADOS E MÉTRICAS

Para avaliar os modelos, foram utilizadas as métricas:

- Acurácia;
- Precisão;
- Recall;
- F1-Score;
- Matriz de Confusão.

8.1 Tabela de Resultados

Tabela 1 – de Resultados

Modelo	Acurácia	Precisão	Recall	F1-Score
KNN	86,34%	86,36%	86,34%	86,34%
Naive Bayes	82,93%	83,15%	82,93%	82,88%
SVM	92,68%	92,71%	92,68%	92,68%
Árvore de Decisão	87,32%	87,36%	87,32%	87,31%
Comitê de Classificadores	92,68%	92,89%	92,68%	92,68%

8.2 Matriz de Confusão do Comitê

Tabela 2 – Matriz de Confusão do modelo de classificação

	Previsto 0	Previsto 1
Real 0	96	4
Real 1	11	94

Os resultados demonstram que o Comitê de Classificadores apresentou o melhor desempenho geral, especialmente em termos de precisão.

9 DISCUSSÃO

Os resultados obtidos demonstram que todos os modelos apresentaram desempenho satisfatório na classificação de pacientes com e sem doença cardíaca.

O modelo Naive Bayes apresentou F1-Score de 82,88% o menor desempenho entre os classificadores avaliados, alcançando F1-Score de 82,88%. Por outro lado, o SVM apresentou excelente desempenho individual, alcançando acurácia de 92,68%.

A utilização do Comitê de Classificadores permitiu combinar as previsões dos quatro modelos, aumentando a robustez do sistema e obtendo a maior precisão do estudo, com 92,89%.

Esses resultados evidenciam a eficácia das técnicas de Ensemble Learning na redução de erros e no aumento da confiabilidade das previsões, especialmente em aplicações médicas onde decisões incorretas podem gerar consequências significativas.

10 CONCLUSÃO

Este trabalho apresentou a construção de um sistema de classificação para predição de doenças cardíacas utilizando técnicas de aprendizado supervisionado. Foram realizadas etapas de análise exploratória, pré-processamento dos dados, treinamento de quatro classificadores individuais e construção de um Comitê de Classificadores baseado em votação majoritária.

Os resultados demonstraram que o Comitê de Classificadores apresentou o melhor desempenho geral, alcançando:

- Acurácia: 92,68%;
- Precisão: 92,89%;
- Recall: 92,68%;
- F1-Score: 92,68%.

Conclui-se que a utilização de técnicas de Ensemble Learning constitui uma estratégia eficiente para aumentar a qualidade das previsões e reduzir erros de classificação em problemas relacionados ao diagnóstico médico.

Como trabalhos futuros, sugerem-se a utilização de técnicas avançadas de ensemble, como Random Forest e Gradient Boosting, além da realização de otimização de hiperparâmetros e validação cruzada para a obtenção de resultados ainda mais robustos.

REFERÊNCIAS

KAGGLE. Heart Disease Dataset. Disponível em: <https://www.kaggle.com>. Acesso em: 08 jun. 2026.

PEDREGOSA, F. et al. Scikit-Learn: Machine Learning in Python. Journal of Machine Learning Research, v. 12, p. 2825-2830, 2011.